

一种多任务学习的储层物性参数预测方法

徐彬森¹ 冯周² 武宏亮² 李宁² 肖立志^{3*}

1 中国石油大学（北京）地球物理学院 北京 102249; 2 中国石油勘探开发研究院 北京 100083;

3 中国石油大学（北京）人工智能学院 北京 102249

1 引言

计算孔隙度（Porosity），含水饱和度（含油气饱和度，Oil Saturation），渗透率（Permeability）等物性参数，是测井储层评价工作的一项重要内容。相关经典公式中存在的系数需要根据油田现场实验去选取；每一个地球物理公式在建模时，更多地考虑的是公式中参数的影响，而缺少考量相应的建模方式对未来相关物性参数计算的影响，基于以上两个因素，每一个物性参数计算结果的好坏将影响到整体物性参数的评价效果。本文以多任务学习为视角，提出一种基于数据驱动的，由常规曲线纵波时差（AC）、自然伽马（GR）、补偿中子孔隙度（CNL）、密度（DEN）、深浅侧向电阻率（RLLD 和 RLLS）六种测井资料同时计算孔隙度、饱和度和渗透率的方法。

2 多任务学习神经网络方法介绍

1997 年卡耐基梅隆大学的 Caruana 在“多任务学习”的论文中认为：多任务学习（Multi-task Learning, MTL）是归纳传递”（本文认为这种归纳传递把已有的数据特征等传递给其他任务，其他任务获得更多维度信息对于目标任务结果的描述，可以提升推理效果）的一种方法。在多任务学习物性参数预测网络中，如果将各个任务重要性设置相同，每一个基础任务分支作为一个单元，这个单元成为一个“基学习网络（器）”，用于对输入数据做相应任务的处理，它由一系列小的算法模块组成，那么若干个单元组合成一个复杂网络，这个网络将完成特定序列的任务。每一个“基学习器”对应一个处理序列，完成相应的物性参数预测任务。本文的基学习器中的模块采用的是神经网络。之所以选择神经网络，是因为已经有一些神经网络方法预测储层参数的相关研究，如安鹏等（安鹏等., 2019）研究表明长短期递归神经网络也可以用于预测泥质含量和孔隙度，结果显示深度学习神经网络要好于传统神经网络方法。杨柳青等（杨柳青., 2019）基于卷积神经网络在孔隙度计算方面的研究也取得好于传统机器学习方法和深度全连接网络的效果。王俊等（王俊等, 2021）提出双向门控循环神经网络（Bidirectional Gated Recurrent Unit, BiGRU）预测储层渗透率。

3 多任务学习网络构建

多任务学习的一个环节就是任务模型间的连接方法，本文主要采用处理信息维度（通道）数的增加（Concatenate or Merge）的方法来进行连接，如图 1 所示，是本文基于基学习网络形成的级联门控递归自注意力网络，执行多任务物性参数预测，这里简称 PSP-Net，红色虚线框表示每一个任务对应的网络分支。每一个任务通过五层双向门控递归神经网络处理后，特征信息（如图中橙黄色线所示）都将传给下一个任务对应网络分支，形成信息“跳层”。

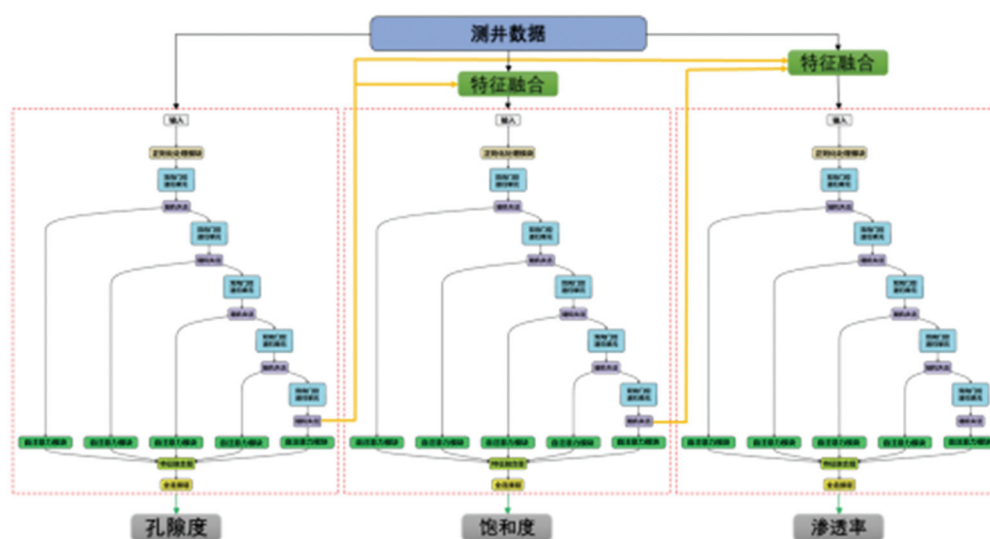


图1 级联门控递归自注意力网络——孔隙度，饱和度和渗透率网络

4 实验

研究实验对目标区块的孔隙度、饱和度和渗透率三种物性参数采用以下四种方法进行预测：双向门控循环神经网络 (Bidirectional Gated Recurrent Unit, BiGRU)、三任务级联的双向门控循环神经网络 (Cascade Bidirectional Gated Recurrent Unit, C_BiGRU)、双向门控自注意力循环神经网络 (Bidirectional Gated Recurrent Unit Self-Attention, BGRU-SA, 即基学习网络 (Base-Network)) 和 PSP-Net 网络。实验的数据来自我国西部某油田区块, 区块井共 145 口井, 包含 108 口训练井 (占比为 70%) 和 37 口 (占比为 30%) 测试井。在选择训练井和测试井时依据的规则是对井位坐标平方和取三位有效数据, 根据 10 折交叉验证的方式选取。对工区的物性参数大致范围值分析, 孔隙度、饱和度和渗透率的数值分布范围依次为 $0\% \sim 26\%$ 、 $0\% \sim 100\%$ 、 $0.01\text{mD} \sim 1000\text{mD}$ 之间。对于渗透率任务, 取渗透率的对数值的一个线性变换作为目标值进行学习。实验选用的深度学习平台的 Tensorflow, 版本为 2.2.0。所有网络学习率一致, 隐藏层单元数一致, 训练相同轮数。

图 2 (图件由 CIFlog 软件绘制), 从左到右依次是三种任务本文实验的方法与现有方法的比较。图 2 中岩心实测层段在 3565–3587 米, 孔隙度的预测结果基本符合岩心实测趋势, 绿色为 PSP-Net 多任务学习方法, 其他颜色为本节开头提到的其他方法。对于饱和度的预测结果, 各种方法吻合度都尚有差距。渗透率预测方面, 各种方法都显现出变化趋势, 部分层段过于剧烈, 特别是 3565–3580 米处。可以看到预测曲线较好反应了输入的六条曲线的形态, 如果后续建模过程中, 训练数据的输入维度能够更加真实地反映对应地层信息, 那么预计能够得到更好的效果。

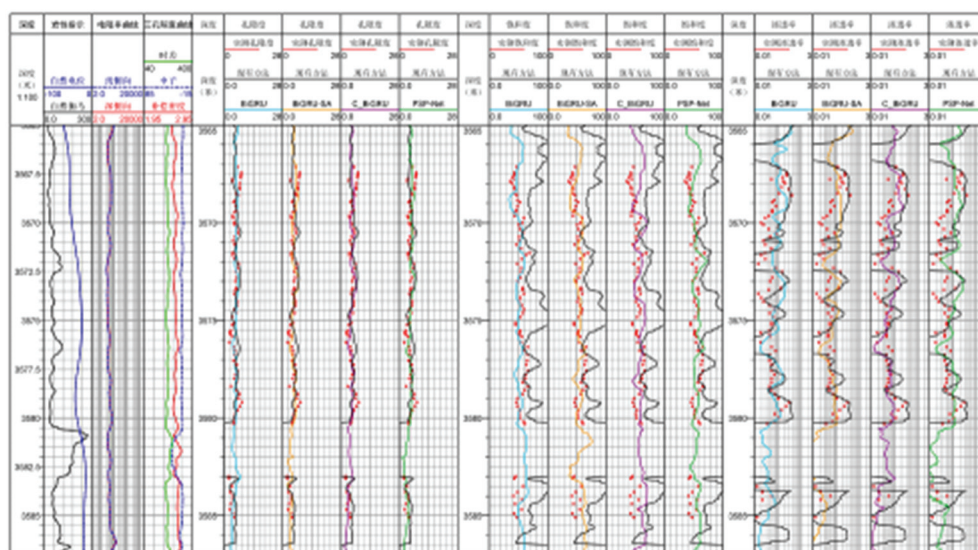


图2 某测试集井物性参数预测结果

5 小结

在 37 口预测井中, 相比较于现有使用的方法, 三项任务降低平均误差的百分比分别为 10.44%、27.79%和 28.83%, 预测的渗透率和实际渗透率在一个数量级范围内。训练简便性和易用性要优于文中其他几种单任务方法, 对于油田老井复查、测井资料补全等工作均能提供帮助。BiGRU 和 BiGRU-SA 两种单任务网络与对应的多任务网络难分伯仲; 在实践时候, 应选较好的单任务网络去构建多任务网络学习模型。本文提出的 PSP-Net 以及文中其他几种参考方法, 在孔隙度和饱和度任务上, 确定系数较好, 而渗透率确定系数要差一些。

参考文献

- 李宁, 1989, 电阻率—孔隙度, 电阻率—含油(气)饱和度关系的一般形式其最佳逼近函数: 地球物理学报, 5(32), 第 580–592 页.
- 洪有密, 1998: 测井原理与综合解释. 第 1 版. 中国石油大学出版社, 北京, Page 159.
- 邱锡鹏, 2020: 神经网络与深度学习, 机械工业出版社.
- 安鹏, 曹丹平, 赵宝银等., 2019, 基于 LSTM 循环神经网络的储层物性参数预测方法研究: 地球物理学进展, 34(05): 1849–1858.
- 杨柳青, 陈伟, 查蓓., 2019, 利用卷积神经网络对储层孔隙度的预测研究与应用: 地球物理学进展, 34(4): 1548–1555. DOI: 10.6038/pg2019CC0528.
- Yang, H., et al., 2020, A Multi-task Learning Model for Daily Activity Forecast in Smart Home: Sensors, 20(7).
- Caruana, R., 1997, Multitask Learning: Machine Learning, (28): p. 41–75.
- Kendall, A., Y. Gal, R. Cipolla., 2018, Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics: IEEE Conference on Computer Vision and Pattern Recognition.
- Vaswani, A., et al., 2017, attention is all you need: Neural Information Processing Systems.
- Huang, G., et al., 2017, Densely Connected Convolutional Networks: IEEE Conference on Computer Vision and Pattern Recognition.

Lin, T., et al., 2017, Feature Pyramid Networks for Object Detection: IEEE Conference on Computer Vision and Pattern Recognition.

王俊, 曹俊兴, 周欣, 2021, 基于深度双向循环神经网络的储层孔隙度预测:地球物理学进展,